Registro de Decisões de Transformação - Integral

Equipe: Gustavo Curado Soares, Marcelo Henrique Data: 2026-11-06 Versão: pipeline completo, etapas 01 a 05

Este documento reúne as quinze fichas obrigatórias. A seção de errata integra as correções quantitativas da Semana 3 e prevalece sobre os números históricos das fichas 02, 03 e 09.

Ficha RDT-01 — Carga completa ou incremental

Decisão: carga completa (full load), reescrevendo o `stg` a cada execução.

Etapa do pipeline: 01_extracao.

O que o dado mostrava: nenhuma origem oferece carimbo confiável de alteração. O legado só tem `DT_CADASTRO` (data de criação), o e-commerce só tem `created_at` (criação) e os arquivos do SAC e do marketplace são exportações concatenadas, sem versão nem data de corte. As contagens na origem são 577.336 (legado), 1.372.367 (e-commerce), 96.140 (SAC) e 160.000 (avaliações).

Alternativas consideradas:

1. Incremental por data de criação (`DT_CADASTRO`/`created_at`). Descartada:

criação não indica alteração; pedidos e clientes podem mudar depois e nunca seriam relidos. Exigiria ainda um estado de controle de "última extração".

2. Incremental por CDC (log binário / triggers). Descartada: os usuários de

origem são somente leitura e não há acesso ao log de replicação.

3. Carga completa, recriando o `stg` do zero a cada execução.

Decisão: alternativa 3.

Justificativa: como não existe coluna de "última modificação" e o pipeline precisa ser reprodutível do zero (entregável 5), a leitura completa é a única que não perde alterações nem depende de estado acumulado. O custo é de tempo, não de informação.

O que se perde: nada de dado; perde-se apenas tempo de reprocessamento (a base inteira é relida a cada execução). Em um cenário de produção com centenas de milhões de linhas, o incremental seria obrigatório por custo.

Registros afetados: 2.205.843 (100% das fontes são relidos).

Asserção associada: contagem do `stg` igual ao `COUNT(*)` da origem, tabela a tabela — 12 asserções na etapa 01 (todas OK).

Ficha RDT-02 — Identidade do cliente entre os dois sistemas

Decisão: o CPF normalizado (só dígitos, válido ou não o dígito verificador) é a ponte; sem CPF, pareia por nome normalizado + cidade + UF apenas 1:1.

Etapa do pipeline: 02_transformacao · `unifica_clientes`.

O que o dado mostrava: o CPF é o único campo presente nos dois sistemas. No legado ele aparece com máscara em ~94% dos casos; no e-commerce vem só em dígitos. Parte dos CPFs está ausente (legado e e-commerce) e uma fração tem dígito verificador inválido. Após a unificação: 114.517 identidades, das quais 15.338 (`AMBOS`) existem nos dois sistemas — 12.605 pareadas por CPF e 2.733 por nome+cidade+UF. Ficaram 29.635 só no legado e 69.544 só no e-commerce. Dos 114.517: 94.560 com CPF válido, 9.282 com CPF inválido e 10.675 sem CPF.

Alternativas consideradas:

1. Parear só por CPF válido. Descartada: jogaria fora os 9.282 vínculos com

CPF inválido — e o mesmo CPF errado é repetido nos dois sistemas, então ele identifica a mesma pessoa tão bem quanto um válido (apenas está errado).

2. Parear só por nome normalizado + cidade + UF. Descartada como regra

primária: homônimos na mesma cidade geram falsos positivos (a colisão medida foi de 13 grupos ambíguos).

3. CPF normalizado como ponte, com fallback nome+cidade+UF quando falta CPF

(escolhida).

Decisão: alternativa 3.

Justificativa: o CPF errado continua sendo um identificador estável porque o erro é sistemático e compartilhado; já o nome sozinho não distingue homônimos. Usar o CPF primeiro e o nome só como reserva minimiza tanto a fragmentação (mesma pessoa em duas linhas) quanto a fusão (duas pessoas em uma).

O que se perde: CPFs com dígito verificador inválido podem, em tese, colidir entre pessoas diferentes — medimos 0 colisões de CPF e 13 de nome+cidade+UF. Pessoas sem CPF e com nome/cidade/UF diferentes entre os sistemas (por digitação) permanecem separadas. Quem decide recompra é afetado nos dois sentidos: fundir dois clientes pode inflar a frequência de um; separar um cliente pode reduzir a dela.

Registros afetados: 114.517 identidades; 15.338 pares `AMBOS` unificados (9.282 deles com CPF inválido e 10.675 clientes sem CPF dependem da regra de reserva ou ficam isolados).

Asserção associada: `dim_cliente: cpf valido duplicado` (=0); `dim_cliente: origem_unificacao` (domínio `{LEGADO, ECOM, AMBOS}`); `dim_cliente <= legado + ecommerce` (cardinalidade preservada).

Ficha RDT-03 — Duplicatas internas do legado

Decisão: deduplicar em duas passagens — por CPF e, depois, por nome+cidade+UF das linhas sem CPF.

Etapa do pipeline: 02_transformacao · `unifica_clientes`.

O que o dado mostrava: o legado tem 47.250 linhas para menos pessoas. Removemos 2.295 duplicatas (1.427 por CPF repetido e 694 "gêmeas" sem CPF que casam nome+cidade+UF com uma linha que tem CPF), restando 44.955 clientes. No e-commerce, a mesma regra removeu 131 linhas.

Alternativas consideradas:

1. Manter tudo. Descartada: infla a contagem de clientes e distorce

frequência e ticket por cliente.

2. Deduplicar só por CPF. Descartada: deixa passar as ~694 gêmeas cujo CPF foi

esvaziado na origem (elas não têm CPF para colidir).

3. Duas passagens (CPF; depois nome+cidade+UF para as sem CPF) — escolhida.

Decisão: alternativa 3.

Justificativa: a primeira passagem resolve os casos inequívocos (mesmo CPF); a segunda captura os gémeos sem CPF sem depender de uma coluna que a origem apagou.

O que se perde: homônimos na mesma cidade/UF sem CPF podem ser fundidos — 13 grupos apresentaram mais de um CPF distinto (sinal de fusão indevida). Esses clientes podem perder compras na consolidação.

Registros afetados: legado 2.295 (4,86% dos 47.250); e-commerce 131 (0,15% dos 85.000).

Asserção associada: `dim_cliente: cpf valido duplicado` (=0); `dim_cliente <= legado + ecommerce (pos dedup)`.

Ficha RDT-04 — Conformação de status, incluindo `payment_declined`

Decisão: hierarquia — `status_conformado` em `{ENTREGUE, CANCELADO, EM_TRANSITO, EM_PROCESSAMENTO}` + `motivo_cancelamento` preenchido só quando a origem distingue.

Etapa do pipeline: 02_transformacao · `conforma_status` → `dw.dim_status`.

O que o dado mostrava: o legado tem 4 estados (`ENTREGUE` 101.192, `CANCELADO` 15.774, `EM TRANSITO` 7.798, `SEPARACAO` 5.236) e o e-commerce tem 5 (`delivered` 207.204, `canceled` 22.413, `shipped` 22.375, `processing` 14.018, `payment_declined` 13.990). O `CANCELADO` do legado agrega duas situações que o e-commerce separa: cancelamento pelo cliente e recusa de pagamento.

Alternativas consideradas:

1. `payment_declined` → `CANCELADO`. Simples, mas apaga a distinção

justamente onde ela existe (13.990 pedidos).

2. Criar `CANCELADO_CLIENTE` e `CANCELADO_PAGAMENTO`. Preserva a informação,

mas cria assimetria: o legado ficaria sempre com um desses vazios/`NULL`.

3. Hierarquia de dois níveis (`status_conformado` + `motivo_cancelamento`) —

escolhida.

Decisão: alternativa 3.

Justificativa: separa o que é comparável (o status de alto nível) do que é detalhe de origem (o motivo). Análises por status usam `status_conformado`; a investigação de recusa de pagamento usa `motivo_cancelamento`.

O que se perde: para o legado o motivo do cancelamento é desconhecido (`NULL` em 15.774 pedidos) — não há como separar recusa de pagamento ali.

Registros afetados: 13.990 pedidos do e-commerce receberam `motivo_cancelamento = RECUSA_PAGAMENTO`; 22.413 receberam `CLIENTE`; 15.774 do legado ficaram sem motivo.

Asserção associada: `status de origem nao mapeado` (=0); `status_conformado` (domínio).

Ficha RDT-05 — Semântica de `VALOR_TOTAL` e `total_amount`

Decisão: reconstruir as medidas a partir dos itens e definir `valor_total = valor_mercadoria + valor_frete − valor_desconto`.

Etapa do pipeline: 02_transformacao · `conforma_valores` → `dw.pedido_conformado`.

O que o dado mostrava (a prova): reconciliando cada cabeçalho com a soma dos itens do próprio pedido: `VALOR_TOTAL` do legado fecha com o frete em 100,00% dos 130.000 pedidos (e só 0,05% sem frete); `total_amount` do e-commerce fecha sem o frete em 100,00% dos 280.000 pedidos (e só 0,06% com frete). Ou seja, não medem a mesma coisa. O frete embutido no legado soma R$ 5.760.932,57; o frete do e-commerce, deixado de fora, soma R$ 10.991.760,38.

Alternativas consideradas:

1. Usar os totais como estão. Descartada: agregaria coisas diferentes e

inflaria o legado em ~R$ 5,7 mi e excluiria ~R$ 11 mi de frete do e-commerce.

2. Ler mercadoria/frete só do cabeçalho. Descartada: o e-commerce não guarda a

mercadoria bruta no cabeçalho; não há como separar sem os itens.

3. Reconstruir mercadoria e desconto dos itens e somar o frete do cabeçalho —

escolhida.

Decisão: alternativa 3.

Justificativa: a soma dos itens é a única fonte da mercadoria bruta nas duas origens, o que torna as medidas comparáveis. A soma dos `valor_total` conformados é R$ 1.027.032.512,48.

O que se perde: a diferença entre o total de cabeçalho e a mercadoria reconstruída; eventuais ajustes lançados só no cabeçalho (não observados) seriam ignorados. Pedidos sem itens ficariam com mercadoria zero — não ocorre (todos os 410.000 têm ao menos um item).

Registros afetados: 410.000 pedidos (100%).

Asserção associada: `valor_mercadoria legado == soma itens` (=0); `valor_mercadoria ecom == soma itens` (=0); e, na Semana 3, a reconciliação financeira (±0,1%).

Ficha RDT-06 — Frete negativo e desconto `-1`

Decisão: frete negativo → valor absoluto; desconto `-1` no legado → 0.

Etapa do pipeline: 02_transformacao · `conforma_valores`.

O que o dado mostrava: frete negativo em 362 pedidos do legado (0,28%) e 812 do e-commerce (0,29%); desconto exatamente `-1` em 4.056 itens do legado (1,02% dos itens).

Alternativas consideradas:

1. Frete negativo — manter. Descartada: produz um `valor_total` que "devolve"

frete, implausível como cobrança.

2. Frete negativo — zerar. Descartada: perde o valor efetivamente cobrado.

3. Frete negativo — tomar o valor absoluto (assumir erro de sinal) —

escolhida.

4. Desconto `-1` — manter. Descartada: converteria o desconto em acréscimo.

5. Desconto `-1` — zerar (assumir sentinela "sem desconto") — escolhida.

Decisão: 3 e 5.

Justificativa: `-1` não é um valor de desconto possível; é o padrão de "sem desconto" que a origem grava. O frete negativo é mais provavelmente erro de sinal da digitação do que um crédito.

O que se perde: se algum frete negativo for um estorno real, tratá-lo como positivo superestima o total desses pedidos; se algum `-1` for um desconto real, zerá-lo subestima. Não há como distinguir com os dados disponíveis.

Registros afetados: 362 + 812 pedidos (frete); 4.056 itens (desconto).

Asserção associada: `valor_mercadoria legado == soma itens` (o desconto clipado entra nessa soma).

Ficha RDT-07 — Mapeamento da taxonomia de produtos

Decisão: mapear o texto livre do legado para a taxonomia de dois níveis do e-commerce quando inequívoco; deixar `categoria_nivel1 = NULL` nos casos ambíguos e preservar `categoria_origem`.

Etapa do pipeline: 02_transformacao · `conforma_categorias` → `dw.dim_produto`.

O que o dado mostrava: o legado tem 27 valores distintos de `CATEGORIA`, sem lista controlada (`ELETRO`, `Eletro-domesticos`, `informatica e games`, `DIVERSOS`, `''`, …). O e-commerce tem taxonomia de dois níveis. Após o mapeamento, 452 produtos (3,01% dos 15.000) ficaram sem `nivel1`: 340 de `DIVERSOS`, `OUTROS` ou `''` e 112 de `informatica e games` (que cobre os ramos Informática e Games). `TV E SOM` foi mapeado só até o nível 1 (`Áudio e TV`).

Alternativas consideradas:

1. Descartar produtos sem taxonomia. Descartada: perde catálogo e itens no

fato.

2. Forçar tudo para um nível1 "OUTROS". Descartada: inventa uma categoria que

a origem não tem e contamina análises.

3. Mapear o inequívoco, deixar `NULL` o ambíguo, preservar `categoria_origem` —

escolhida.

Decisão: alternativa 3.

Justificativa: não se deve inventar um nível que o dado não sustenta. Manter `categoria_origem` permite refazer o mapeamento depois sem tocar nos fatos.

O que se perde: qualquer análise por categoria exclui 3,01% dos produtos e, portanto, os itens associados; `informatica e games` (112 produtos) não pode ser atribuído a um único nível1.

Registros afetados: 452 produtos (3,01% da `dim_produto`; 15.000 linhas).

Asserção associada: `dim_produto: descricao nula` (=0) — a dimensão não descarta o produto por falta de categoria.

Ficha RDT-08 — Classificação e tratamento de cada tipo de ausência

Decisão: classificar toda ausência como não coletada, não aplicável, sentinela ou erro, e tratá-las de forma distinta — nunca imputar média. Sentinela de data e erro de data viram `NULL` mais o indicador `entrega_sem_data`.

Etapa do pipeline: 02_transformacao · `trata_datas_e_ausencias`.

O que o dado mostrava:

Campo	Tipo de ausência	Registros
`DT_ENTREGA` = `1900-01-01`	sentinela	1.025
`DT_ENTREGA` < `DT_PEDIDO`	erro de registro	2.458
`DT_ENTREGA` vazia em pedido não entregue	não aplicável	101.604
`CPF` ausente (legado + e-commerce)	não coletada	10.675
`VL_DESCONTO` = `-1`	sentinela	4.056
`data_fechamento` vazia no SAC	não aplicável (em aberto)	5.856
`nota_satisfacao` vazia / `'0'`	não coletada / fora do domínio	8.682 / 2.830
`tempo_resolucao_horas` negativo	erro	353
`rating` ausente (avaliações)	não coletada	4.831

Alternativas consideradas:

1. Imputar a média em cada campo vazio. Descartada: inventa dado em campos que

são sentinela ou não aplicável (a entrega de um pedido cancelado não existe).

2. Descartar as linhas afetadas. Descartada: perderia o pedido inteiro por

causa de um único campo.

3. `NULL` + indicador para as sentinelas de entrega — escolhida.

Decisão: alternativa 3.

Justificativa: distinguir "não existe" de "não foi registrado" preserva a hipótese de que falhas de registro se concentram em entregas problemáticas — hipótese que o indicador `entrega_sem_data` deixa testar.

O que se perde: `dias_entrega` fica indisponível para 3.483 pedidos (0,85%): 1.025 por sentinela + 2.458 por erro. Qualquer prazo médio passa a excluí-los e fica levemente enviesado para baixo se as falhas se concentrarem em entregas lentas.

Registros afetados: ver tabela (2.458 + 1.025 + 101.604 de entrega; e os demais campos acima).

Asserção associada: `dias_entrega negativo` (=0) — nenhuma entrega anterior ao pedido sobrou.

Ficha RDT-09 — Padronização de fuso horário

Decisão: padronizar todos os instantes para America/Sao_Paulo (UTC-3), armazenados sem fuso.

Etapa do pipeline: 02_transformacao · `trata_datas_e_ausencias`.

O que o dado mostrava: o e-commerce grava `placed_at`/`delivered_at` como `TIMESTAMPTZ` (com fuso); o legado grava `DATETIME` sem fuso; o SAC usa `dd/mm/aaaa`; nas avaliações, 128.085 timestamps vêm com fuso e 31.915 (19,95%) vêm sem fuso.

Alternativas consideradas:

1. Guardar cada origem no seu fuso. Descartada: comparações entre sistemas

ficariam erradas em até 3 horas (ex.: uma compra de 31/06 23:00 viraria 01/07 02:00 e cairia no lado errado da data de corte).

2. Converter tudo para UTC. Correta, mas dificulta a leitura local dos

relatórios.

3. Converter tudo para America/Sao_Paulo (UTC-3), sem fuso — escolhida.

Decisão: alternativa 3.

Justificativa: um único fuso elimina as comparações ambíguas; UTC-3 fixo é fiel porque o Brasil não usa horário de verão desde 2019, e uma data local é mais legível para a área de marketing.

O que se perde: os 31.915 timestamps sem fuso são interpretados como UTC antes da conversão — uma suposição que pode deslocar esses instantes em até 3 horas e, na fronteira da data de corte, trocar o lado de um pedido. A informação de fuso original não é preservada.

Registros afetados: 410.000 pedidos + 160.000 avaliações (100%); suposição aplicada a 31.915 avaliações.

Asserção associada: `dias_entrega negativo` (=0) — a padronização de fuso não pode produzir entrega anterior ao pedido.

Errata da Semana 2

Errata RDT-02 — identidade do cliente

A regra de identidade não mudou: CPF normalizado (válido ou não) é a ponte e, sem CPF, o fallback é nome normalizado + cidade + UF. O que mudou foi a execução do fallback: ele passou a aceitar apenas pares 1:1. A versão anterior permitia que uma chave nome+cidade+UF casasse vários clientes de um lado com vários do outro, o que criava linhas ambíguas e 31 IDs naturais duplicados na dimensão (18 `id_legado` e 13 `id_ecommerce`).

Números finais, substituindo os da Semana 2:

Medida	Valor final
`dim_cliente`	114.548
`AMBOS`	15.276
somente `LEGADO`	29.679
somente `ECOM`	69.593
pareados por CPF	12.605
pareados por nome+cidade+UF	2.671
CPF válido	94.620
CPF inválido	9.289
sem CPF	10.639
colisões de CPF entre pessoas	0
grupos ambíguos de nome+cidade+UF	13
pares nome+cidade+UF descartados por não serem 1:1	62

A dimensão cresceu de 114.517 para 114.548 (+31) e os 31 IDs naturais duplicados desapareceram. O risco declarado agora é mais estreito: 13 grupos de homônimos não foram pareados entre origens pelo fallback 1:1; eventuais fusões dentro de cada origem por nome+cidade+UF continuam possíveis e ficam registradas. Quem ficou sem par continua como uma linha de origem única.

Asserções associadas: `dim_cliente: id_legado duplicado` (=0), `dim_cliente: id_ecommerce duplicado` (=0), `mapa_cliente_origem: chave duplicada` (=0), `mapa_cliente_origem: linhas` (=132.250).

Errata RDT-03 — duplicatas internas

A decomposição final é:

Origem	Linhas brutas	Removidas por CPF	Removidas por nome+cidade+UF	Linhas após dedup
LEGADO	47.250	1.427	694 gêmeas sem CPF + 174 duplicatas sem CPF	44.955
ECOM	85.000	3	122 gêmeas sem CPF + 6 duplicatas sem CPF	84.869

Total removido: 2.295 no legado (4,86%) e 131 no e-commerce (0,15%). A Semana 2 já registrava 2.295 e 131, mas não separava as 174 duplicatas sem CPF do legado; a separação está agora explícita.

O mapa de procedência `dw.mapa_cliente_origem` tem 132.250 linhas, uma para cada cliente bruto das duas origens (47.250 + 85.000). Ele preserva a ligação `id original` → `id canônico` para todos os clientes, inclusive os 2.426 que saíram da dimensão (2.295 + 131).

Asserção associada: `mapa LEGADO: canonico ausente na dim` (=0), `mapa ECOM: canonico ausente na dim` (=0).

Errata RDT-09 — fuso horário

A Semana 2 dizia que os 31.915 timestamps sem fuso eram interpretados como UTC. Isso estava errado e foi corrigido: timestamps sem offset são interpretados como hora local de America/Sao_Paulo (UTC-3); timestamps com offset são convertidos para UTC-3. A implementação anterior usava `utc=True` diretamente e transformava os 31.915 valores sem offset em `NaT`, deixando 128.085 avaliações com data e 31.915 sem data. Após a correção, 160.000 avaliações têm data, no intervalo 2023-01-01 a 2025-12-30.

Distribuição real: 128.085 timestamps com fuso e 31.915 sem fuso (19,95%). A hipótese de que o horário sem offset é local é declarada; ela pode deslocar um instante em até 3 horas na fronteira do dia.

Asserção associada: `avaliacoes: data nula` (=0).

Errata RDT-13 — SAC e avaliações na etapa 2

O CSV do SAC contém 1.140 linhas exatamente repetidas (mesmo protocolo e mesmos campos). O grão de `fato_atendimento` é um atendimento, então o protocolo foi deduplicado: 96.140 linhas de origem → 95.000 atendimentos. As 1.140 linhas removidas não representam atendimentos distintos.

As avaliações continuam 160.000, todas ligadas a um pedido. A ligação não é só com o e-commerce: 119.984 avaliações pertencem a pedidos ECOM e 40.016 a pedidos LEGADO (os `product_ref` no formato `LEG-<id>`).

Ficha RDT-10 — Itens órfãos

Decisão: itens cujo pedido não existe no `fato_pedido` vão para `qa.quarentena_item_pedido`; não entram em `dw.fato_item_pedido` e não geram pedido sintético.

Etapa do pipeline: 03_carga_dw → `carrega_fato_item`.

O que o dado mostrava: dos 1.392.453 itens conformados, 20.577 (1,48%) não tinham pedido correspondente:

Origem	Itens órfãos	Valor da linha
ECOM	14.709	R$ 2.204.879,10
LEGADO	5.868	R$ 586.213,20
Total	20.577	R$ 2.791.092,30

Alternativas consideradas:

1. Descartar os itens. Perde definitivamente a única evidência de demanda

desses produtos; não é reversível.

2. Criar um pedido sintético “desconhecido”. Preserva o valor no esquema

estrela, mas inventa um pedido e contamina contagens, ticket médio e frequência.

3. Quarentena com a chave natural e o valor. Mantém a evidência fora do

esquema estrela, sem inventar pedido.

Decisão: alternativa 3.

Justificativa: o esquema estrela só deve conter fatos com dimensões válidas; um item sem pedido não tem `pedido_sk` legítimo. A quarentena preserva o dado e deixa explícito que 1,48% dos itens não foram analisados.

O que se perde: esses itens não entram em análises de produto, categoria ou receita do DW. O valor de R$ 2.791.092,30 (0,28% do valor conformado dos itens) fica fora dos indicadores. A perda é reversível porque a quarentena guarda as chaves e os valores.

Registros afetados: 20.577 itens (1,48% de 1.392.453); R$ 2.791.092,30.

Asserções associadas: `quarentena: itens sem pedido` (=20.577), `fato_item: linhas` (=1.371.876), `fato_item: produto sem mapeamento` (=0).

Ficha RDT-11 — Declaração de grão

Decisão: o grão é declarado antes da carga:

Uma linha de `dw.fato_pedido` representa um pedido de uma das duas origens, identificado por `(id_origem, sistema_origem)`.

Uma linha de `dw.fato_item_pedido` representa uma linha de item de um pedido válido. A chave surrogate é `item_sk`; `(pedido_sk, produto_sk)` não é única quando o mesmo produto aparece em linhas separadas do mesmo pedido.

Etapa do pipeline: 03_carga_dw → `carrega_fato_pedido` e `carrega_fato_item`.

O que o dado mostrava: 130.000 pedidos LEGADO + 280.000 ECOM = 410.000 pedidos; 1.392.453 itens conformados, dos quais 1.371.876 têm pedido. A soma de `qtd_itens` dos pedidos é exatamente 1.371.876, igual à contagem de itens válidos, o que confirma que o grão do pedido não foi multiplicado pela junção com itens.

Alternativas consideradas:

1. Grão de pedido com uma linha por item. Seria grão de item disfarçado:

duplicaria o valor do pedido e destruiria a soma de receita.

2. Grão de item com o pedido agregado. Perderia a possibilidade de separar

frete/desconto no nível do pedido.

3. Dois fatos explícitos, um por grão, ligados por `pedido_sk`.

Decisão: alternativa 3.

Justificativa: a pergunta de recompra é por cliente/pedido; a análise de produto é por item. Separar os grãos mantém as duas perguntas possíveis sem misturar unidades de medida.

O que se perde: não há perda de pedidos válidos; os 20.577 itens sem pedido ficam na quarentena (RDT-10). O item órfão não pode ser somado ao pedido, mas essa soma seria inválida de qualquer forma.

Registros afetados: 410.000 pedidos (100% dos pedidos); 1.371.876 itens válidos (98,52% de 1.392.453); 20.577 itens em quarentena (1,48%).

Asserções associadas: `fato_pedido: linhas` (=410.000), `fato_item: linhas` (=1.371.876), `fato_pedido: FK orfa` (=0), `fato_pedido: dias_entrega negativo` (=0).

Ficha RDT-12 — Pedidos sem cliente correspondente

Decisão: resolver a identidade pelo mapa canônico `dw.mapa_cliente_origem`; não criar cliente sentinela “DESCONHECIDO”.

Etapa do pipeline: 02_transformacao → `grava_mapa_clientes`; 03_carga_dw → `carrega_fato_pedido`.

O que o dado mostrava: depois da deduplicação, 6.388 pedidos LEGADO e 448 pedidos ECOM referenciavam IDs de clientes que não existiam mais na dimensão — 6.836 pedidos aparentemente órfãos. A causa não era dado faltante: era a deduplicação sem mapa de procedência. Os clientes removidos tinham sido fundidos em outro ID canônico.

Alternativas consideradas:

1. Criar um cliente sentinela. Fácil, mas joga 6.836 pedidos em uma

identidade falsa e distorce frequência, recência e ticket.

2. Descartar os pedidos. Perde 1,67% dos pedidos e receita real.

3. Mapa `id original → id canônico`, mantendo todos os pedidos ligados ao

cliente que absorveu a linha duplicada.

Decisão: alternativa 3.

Justificativa: a deduplicação é uma decisão sobre a dimensão; o pedido não deve pagar por ela. O mapa é uma ponte explícita e auditável entre a chave da origem e a identidade final.

O que se perde: nada de pedido. Se a regra de deduplicação tiver fundido duas pessoas, o mapa propaga essa fusão para os pedidos — o risco já declarado na RDT-02. O mapa não corrige a decisão; apenas a torna rastreável.

Registros afetados: 6.836 pedidos inicialmente sem cliente (1,67% de 410.000); 0 após o mapa. O mapa cobre 132.250 clientes brutos e foi usado em 410.000 pedidos.

Asserções associadas: `fato_pedido: cliente sem mapeamento (=0)`, `fato_pedido: FK orfa (=0)`, `mapa_cliente_origem: linhas (=132.250)`.

Ficha RDT-13 — Atendimentos e avaliações sem pedido

Decisão: manter SAC e avaliações ligados por chave natural ao pedido; na carga, usar o `cliente_sk` do pedido para o SAC e mapear o produto por `SKU-` ou `LEG-` para as avaliações. Não há fallback nulo: os dados atuais têm 0 casos sem pedido, e a carga aborta explicitamente se aparecer um.

Etapa do pipeline: 02_transformacao → `liga_sac_e_avaliacoes`; 03_carga_dw → `carrega_fatos_auxiliares`.

O que o dado mostrava:

• SAC: 96.140 linhas de origem, 1.140 duplicatas exatas, 95.000

atendimentos distintos; 5.791 sem data de fechamento (em aberto); 0 sem pedido após a ligação.

• Avaliações: 160.000; 0 sem pedido; 119.984 de pedidos ECOM e

40.016 de pedidos LEGADO; 40.016 `product_ref` no formato `LEG-<id>` e 119.984 no formato `SKU-<id>`; todas as 160.000 encontraram produto.

• Datas das avaliações: 2023-01-01 a 2025-12-30, sem nulos após a correção

de fuso (Errata RDT-09).

Alternativas consideradas:

1. Descartar as linhas sem pedido. Perderia sinal de atendimento/avaliação

por causa de uma referência quebrada.

2. Manter com `pedido_sk` nulo e resolver o cliente pelo CPF. Funciona para

o SAC, mas o CPF tem 9.882 casos sem correspondência na dimensão; o pedido é uma ponte melhor.

3. Manter a linha e usar o pedido para obter `cliente_sk` (escolhida).

Decisão: alternativa 3.

Justificativa: o pedido é a chave que liga o evento ao cliente de forma consistente com o fato principal; o CPF é uma ponte secundária e falha em 9.882 atendimentos. As avaliações de pedidos LEGADO também precisam ser tratadas — assumir que toda avaliação é ECOM perderia 40.016 linhas.

O que se perde: as 1.140 linhas duplicadas do SAC não representam atendimentos distintos; a deduplicação não perde informação, apenas remove repetição exata. Nenhuma avaliação é descartada. O `cliente_sk` do SAC vem do pedido, não do CPF; se o CPF do SAC divergir do cliente do pedido, prevalece o pedido — uma escolha declarada.

Registros afetados: 1.140 linhas de SAC removidas (1,19% de 96.140); 95.000 atendimentos e 160.000 avaliações carregados; 0 sem pedido.

Asserções associadas: `fato_atendimento: SAC sem pedido (=0)`, `fato_atendimento: linhas (=95.000)`, `fato_avaliacao: avaliacao sem pedido (=0)`, `fato_avaliacao: linhas (=160.000)`, `fato_avaliacao: produto nao mapeado (=0)`.

Ficha RDT-14 - Desenho dos atributos da ABT e ausência de vazamento

Decisão: adotar uma fotografia por cliente em `2025-06-30`, incluindo apenas clientes com algum pedido até o corte. O alvo é recompra não cancelada entre `2025-07-01` e `2025-09-28`; todos os atributos da versão correta usam somente eventos disponíveis até o corte.

Etapa do pipeline: `04_abt.py --correta`.

O que o dado mostrava: a população elegível contém 107.091 clientes dos 114.548 clientes conformados (93,49%). Há 24.008 positivos (22,42%). A ABT possui 12 atributos preditivos: recência, frequência, valor monetário, ticket médio, prazo médio, taxa de cancelamento, categorias distintas, canal predominante, atendimentos SAC, nota média, tempo como cliente e quantidade de itens. Existem 2.945 recências nulas (2,75%), 7.388 prazos nulos (6,90%) e 38.876 notas nulas (36,30%); esses nulos significam ausência de evento aplicável, e não zero.

Alternativas consideradas:

1. Incluir todos os 114.548 clientes. Descartada porque 7.457 ainda não tinham

histórico de pedido no instante da previsão; seriam linhas sem exposição ao fenômeno estudado.

2. Imputar zero em recência, prazo e nota. Descartada porque zero teria conteúdo

semântico falso: recência zero significa compra no dia do corte e nota zero nem pertence à escala observada.

3. Manter nulos semanticamente corretos, usar zero apenas em contagens sem evento

e limitar cada consulta à data de corte. Escolhida.

Decisão e justificativa: alternativa 3. Ela preserva a diferença entre "nenhum evento" e "valor igual a zero" e garante que cada atributo pudesse ser conhecido quando a campanha fosse dimensionada.

O que se perde: os 7.457 clientes sem pedido anterior ao corte não recebem previsão. Modelos que não tratam nulos exigem imputação dentro de cada partição; isso acrescenta uma hipótese ao treinamento, mas evita inventar valores no ETL.

Registros afetados: 107.091 linhas construídas; 7.457 clientes excluídos da população por falta de histórico (6,51% da dimensão). Nulos preservados: 2.945, 7.388 e 38.876 nos três atributos citados.

Asserção associada: unicidade de `cliente_sk`, cardinalidade da junção, `data_corte = 2025-06-30`, alvo em `{0,1}`, frequências não negativas, zero recências negativas e recálculo amostral de frequência, recência e prazo apenas com pedidos anteriores ao corte.

Ficha RDT-15 - Vazamentos deliberados na versão de comparação

Decisão: produzir um contraexemplo controlado no qual somente três aspectos mudam: `recencia_dias` e `frequencia_pedidos` passam a consultar toda a série de pedidos; `valor_monetario_z` usa média e desvio calculados na base inteira antes da separação treino/teste. Os demais atributos, população, alvo e fluxo de avaliação permanecem iguais.

Etapa do pipeline: `04_abt.py --vazamento` e fluxos do Orange.

O que o dado mostrava: 43.095 clientes (40,24% da ABT) mudam em recência e frequência por possuírem pedido posterior ao corte; nessas linhas a recência fica negativa, revelando diretamente o futuro. O z-score global afeta as 107.091 linhas e varia de -1,352655 a 7,700743. No teste estratificado 70/30 no Orange, a Árvore sobe de AUC 0,484417 para 0,955662 e de acurácia balanceada 0,523317 para 0,951820.

Alternativas consideradas:

1. Introduzir o próprio alvo como atributo. Descartada por ser um vazamento

trivial, sem valor didático.

2. Alterar datas, população e atributos ao mesmo tempo. Descartada porque

impediria atribuir a diferença observada ao vazamento.

3. Alterar apenas dois atributos temporais e acrescentar uma normalização global,

mantendo todo o restante idêntico. Escolhida.

Decisão e justificativa: alternativa 3. O desenho isola um vazamento óbvio (atributos temporais que olham o futuro) e um sutil (parâmetros de transformação estimados antes da partição), permitindo medir ambos.

O que se perde: a versão vazada não responde à pergunta de negócio e não pode ser usada em produção. O bom desempenho aparente perde validade causal e operacional; ele serve somente como evidência experimental.

Registros afetados: 43.095 de 107.091 linhas nos dois atributos temporais (40,24%); 107.091 de 107.091 no z-score global (100%).

Asserção associada: a versão vazada deve conter ao menos uma recência negativa e o z-score global deve ter média aproximadamente zero. Essas asserções confirmam que o contraexemplo foi realmente introduzido; elas não o aprovam como dado de produção.

Tabela-resumo integral

Ficha	Decisão principal	Registros afetados	Percentual	Informação perdida ou risco
01	Carga completa	2.205.843	100%	Tempo de reprocessamento
02	Identidade por CPF; fallback 1:1 por nome+cidade+UF	132.250 brutos	100%	Possíveis homônimos não pareados
03	Deduplicação interna com mapa de procedência	2.426 removidos	1,83%	Possíveis homônimos fundidos
04	Status hierárquico e motivo	52.177 pedidos	12,73%	Motivo desconhecido no legado
05	Valor comparável reconstruído pelos itens + frete	410.000	100%	Ajustes só de cabeçalho
06	Frete negativo em módulo; desconto -1 vira zero	5.230 eventos	-	Possível estorno reinterpretado
07	Taxonomia só quando inequívoca	452 produtos	3,01%	Categoria analítica ausente
08	Ausências classificadas, sem imputação média	3.483 sem prazo	0,85% pedidos	Data real irrecuperável
09	Horários em America/Sao_Paulo	570.000 eventos	100%	Fuso original não preservado
10	Itens órfãos em quarentena	20.577 itens	1,48%	Valor fora dos fatos
11	Fatos separados por grão	1.781.876 fatos	100%	Nenhuma perda adicional
12	Pedido ligado pelo mapa canônico	6.836 pedidos	1,67%	Propaga eventual fusão de identidade
13	SAC/avaliação ligados pelo pedido	256.140 brutos	100%	1.140 repetições exatas removidas
14	Fotografia da ABT no corte	107.091 clientes	93,49% da dimensão	7.457 sem histórico fora da população
15	Dois vazamentos temporais + z-score global	43.095 / 107.091	40,24% / 100%	Versão inválida para produção

Reflexão final

A decisão com maior potencial para alterar o modelo é a RDT-02. Fundir duas pessoas soma históricos e pode transformar dois não recompradores em uma linha positiva; separar uma pessoa em dois IDs faz o inverso. Não executamos uma análise de sensibilidade completa para outra regra de identidade, portanto esta conclusão é uma hipótese fundamentada, não um resultado medido.

A RDT-06 mostra uma conveniência técnica com efeito sobre pessoas. Interpretar frete negativo como erro de sinal pode converter um estorno real em gasto. Em uma campanha, esse cliente pareceria mais valioso e poderia receber tratamento diferente. A regra é defensável nos dados disponíveis, mas exigiria validação com a área financeira antes de produção.

As informações mais valiosas que faltaram foram: identificador corporativo único do cliente, histórico de alterações, semântica formal dos totais e motivo do cancelamento no legado, além do fuso nos timestamps incompletos. Elas reduziriam as decisões por aproximação justamente nos pontos que mais afetam identidade, tempo e dinheiro. O experimento final reforça a principal lição: uma métrica alta não valida o processo. A Árvore quase dobrou a AUC ao receber informação futura; o resultado mais impressionante era o menos utilizável.