INSTITUTO FEDERAL DE MATO GROSSO – IFMT

Alunos: Gustavo Curado Soares, Marcelo Henrique

Professor: Orlando Junior Disciplina: Mineração de Dados

Relatório semana 1 – “Perfilar antes de tocar”

Analisei as quatro bases de dados do cenário, que totalizam 2.205.843 registros brutos. Dividi minha contagem da seguinte forma: 577.336 registros no ERP legado, 1.372.367 na plataforma de e-commerce, 96.140 no arquivo do SAC e 160.000 objetos nas avaliações do marketplace.

1. Cobertura de Dados e Chaves de Junção

Ao avaliar os campos candidatos a conectar as diferentes bases, encontrei desafios significativos de formatação e sobreposição:

- **CPF:** Notei uma alta divergência de formatos entre os sistemas. No legado, 94,37% dos CPFs preenchidos (40.416 registros) contêm máscara, enquanto o SAC apresenta 59,93% (57.620 registros) com máscara. O e-commerce, por sua vez, guarda apenas dígitos, o que me obriga a normalizar esses dados antes de qualquer junção. A interseção real entre o legado e o e-commerce é de apenas 12.605 CPFs distintos. Além disso, o **CPF não atua como chave única** nem mesmo dentro do legado, pois encontrei 1.427 valores repetidos.
- **E-mail:** Embora o preenchimento seja de 100%, **o campo é inútil para cruzar as bases de clientes**. O sistema legado utiliza domínios como @exemplo.com.br, enquanto o e-commerce usa @correio.com.br, resultando em zero interseção.
- **Identificadores Numéricos:** Os IDs de cliente, pedido e produto se sobrepõem integralmente nos domínios numéricos, mas **representam entidades diferentes**. Se eu fizesse um relacionamento direto pelo ID do

cliente, criaria 34.645 cruzamentos falsos, pois 73,32% dos pareamentos pertenceriam a pessoas distintas.

- **Chaves de Sucesso:** Para cruzar o SAC com os pedidos, consegui 100% de correspondência ao usar a chave composta por “origem_sistema” e “id_pedido_origem”. Nas avaliações, a referência do pedido funcionou perfeitamente após a remoção dos prefixos LEG- e ECOM-. Contudo, para encontrar o SKU do produto nas avaliações do legado, terei que reconstruir a chave usando o padrão LEG-<ID_PRODUTO> para que o cruzamento funcione.

2. Conflitos de Semântica e Regras de Negócio

Descobri que os sistemas frequentemente usam o mesmo rótulo para descrever conceitos completamente diferentes:

- **Status do Pedido:** O legado trabalha com 4 estados, contendo exclusividades como "SEPARACAO" e "EM TRANSITO". O e-commerce trabalha com 5 estados, possuindo exclusivamente o status de "payment_declined". O próprio conceito de "cancelado" diverge, já que o e-commerce separa recusa de pagamento do cancelamento padrão, enquanto o legado agrupa tudo.
- **Conceito de Canal:** A palavra "canal" tem zero valores em comum entre as três bases. Nos sistemas de pedido, refere-se ao canal de venda (LOJA e SITE no legado; web e app no e-commerce). No SAC, o termo descreve o canal de atendimento (CHAT, telefone, WHATSAPP, etc.), guardando inclusive o mesmo canal em formatos diferentes de texto.
- **Preços:** Os sistemas misturam preço de tabela com preço praticado. No legado, o valor unitário diverge do preço de tabela em 99,93% dos itens. No e-commerce, o preço unitário diverge do preço de lista em 99,94% dos registros. Nenhum desses campos é diretamente intercambiável.
- **Incompatibilidade do Valor Total (Crítico):** O campo VALOR_TOTAL do legado não é o mesmo que o total_amount do e-commerce. Ao reconciliar as contas, provei que o legado inclui o valor do frete no cálculo total em 100% dos pedidos cobrados, enquanto o e-commerce considera

estritamente a mercadoria líquida, deixando o frete de fora. Se eu somasse os dois diretamente, inflaria o lado do legado em mais de R$ 5,7 milhões e deixaria quase R$ 11 milhões de frete do e-commerce fora dos agregados cruzados.

3. Anomalias Identificadas

Classifiquei os problemas de dados em duas frentes de atuação:

- **Anomalias Internas (Quantificáveis agora):** São problemas estruturais dentro de cada base. No SAC, encontrei 1.140 linhas duplicadas exatas e durações negativas de atendimento. No ERP legado, observei 1.025 datas de entrega fictícias marcadas como 1900-01-01, fretes negativos e 5.868 itens de pedido órfãos. O e-commerce apresentou entregas registradas antes da data do pedido e 14.709 itens órfãos. Nas avaliações, identifiquei campos faltantes e ausência de fuso horário.
- **Anomalias de Integração (Surgem no cruzamento):** São os problemas mais complexos, pois não existem nas fontes isoladas. Elas incluem a colisão dos IDs numéricos, choques de preços de tabela no mesmo produto e a identidade dividida dos clientes. Dos 12.605 CPFs em comum, 100% apresentam divergência de nome devido ao padrão de letras maiúsculas no legado contra formato misto no e-commerce.

4. Definição da Granularidade

Com base nesse diagnóstico, estabeleci os seguintes grãos para a modelagem das tabelas-fato:

- Uma linha de **dw.fato_pedido** representa um pedido, e apenas um pedido, de um unico sistema de origem, identificado de forma unica pelo par (id_origem, sistema_origem); as medidas valor_mercadoria, valor_frete, valor_desconto, valor_total e qtd_itens sao atributos de agregacao desse proprio pedido.
- Uma linha de **dw.fato_item_pedido** representa um item de um pedido, ou seja, uma linha da tabela de itens da origem, ligada a exatamente um dw.fato_pedido e a exatamente um dw.dim_produto.

- Uma linha de **dw.fato_atendimento** representa um atendimento do SAC, identificado de forma unica pelo campo protocolo.
- Uma linha de **dw.fato_avaliacao** representa uma avaliacao de produto enviada ao marketplace, identificada de forma unica pelo campo review_id.