Experimento de vazamento - resultados da Semana 4

Equipe: Gustavo Curado Soares, Marcelo Henrique Data: 2026-11-06

Pergunta e desenho

Predizer se um cliente com histórico até 30/06/2025 fará ao menos uma compra não cancelada de 01/07/2025 a 28/09/2025. A população possui 107.091 clientes e 24.008 positivos (22,42%). Foi aplicada uma separação estratificada e replicável: 70% para treino (74.964 linhas) e 30% para teste (32.127), com a mesma semente, modelos e tratamento de ausências nas duas versões.

A versão correta limita todos os atributos ao corte. A versão de comparação usa o futuro em recência e frequência e calcula um z-score global antes da partição. Os três modelos exigidos são Naive Bayes, Logistic Regression e Tree. AUC é a métrica principal; acurácia balanceada impede que a classe majoritária esconda o desempenho sobre os recompradores. As métricas abaixo foram executadas pelo Orange 3.39 com o mesmo particionamento configurado nos arquivos `.ows`.

Resultados

Modelo	AUC correta	AUC vazada	Diferença	Bal. correta	Bal. vazada	Diferença
Naive Bayes	0,576802	0,879834	+0,303032	0,524992	0,767283	+0,242291
Logistic Regression	0,536168	0,841793	+0,305625	0,500393	0,606365	+0,105972
Tree	0,484417	0,955662	+0,471245	0,523317	0,951820	+0,428503

Na ABT correta, o melhor AUC foi o do Naive Bayes (0,576802), ainda modesto. Isso é aceitável: o projeto avalia a validade do processo, não uma meta arbitrária de desempenho. Na ABT vazada, a Árvore atinge AUC 0,955662 e acurácia balanceada 0,951820. O salto não representa melhor generalização; representa acesso a pedidos posteriores ao instante de previsão.

O vazamento sutil

Foi repetida a avaliação da ABT vazada removendo somente `valor_monetario_z`.

Modelo	Delta AUC ao incluir z global	Delta acurácia balanceada
Naive Bayes	-0,004052	-0,007237
Logistic Regression	+0,001260	-0,001638
Tree	0,000000	0,000000

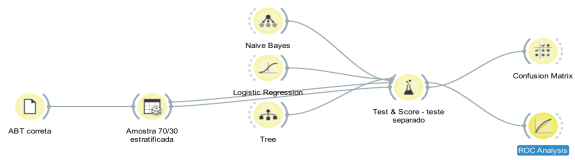
O efeito foi pequeno e inconsistente: imperceptível na regressão e na árvore e ligeiramente negativo no Naive Bayes. Isso não torna a prática aceitável. A transformação aprendeu parâmetros do conjunto de teste e viola o contrato de avaliação, ainda que esta base específica não tenha produzido ganho.

Como detectar o erro sem conhecer a origem

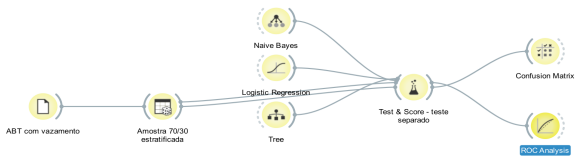
Primeiro, reconstruir cada atributo para uma amostra usando apenas dados disponíveis em 30/06/2025. Essa auditoria encontra 43.095 divergências em recência e frequência. Segundo, verificar domínios temporais: recência negativa é impossível numa fotografia do passado, e há exatamente 43.095 casos na versão vazada. Terceiro, executar validação temporal, treinando em períodos antigos e testando em períodos posteriores; uma queda abrupta em relação à partição aleatória é sinal de informação indisponível. Quarto, encapsular imputação, normalização e seleção de atributos dentro de cada partição. Por fim, desconfiar de saltos grandes sem nova fonte operacional: a Árvore passou de AUC 0,484 para 0,956 apenas trocando o arquivo.

Conclusão

O modelo correto é o único candidato a uso. Seu desempenho modesto pede novos atributos disponíveis no corte ou outra formulação de negócio, nunca a inclusão do futuro. O experimento mostra que métricas excelentes podem ser evidência de erro: a rastreabilidade temporal e as asserções da ABT são mais importantes que o placar isolado.



Fluxo Orange - ABT correta



Fluxo Orange - ABT com vazamento